

Detekcija anomalija u slikama

Nikola Mamić, Petar Matejčić i Jakov Tušek

Svibanj 2026.

1 Uvod

Detekcija anomalija u slikama je bitna u raznim primjenama - otkrivanje defekata u tekstilu, otkrivanje tumora, detekcija podvodnih mina itd. Problem korektnog i preciznog pronalaženja anomalija otežan je time što su anomalije rijetke (većina podataka neće sadržavati anomalije), visokom dimenzionalnosti podataka i vremenom računanja potrebnim za detekciju na velikim slikama. U našem radu predstavljamo uspoređujemo statistički pristup problemu i pristup koji koristi difuzijska preslikavanja.

2 Detekcija anomalija koristeći difuzijska preslikavanja

2.1 Formalizacija problema

Pretpostavljamo sljedeće o anomalijama u našim podacima:

- Anomalije su veće od jednog piksela
- Vrlo su male, pozadina dominira i formira gust klaster
- Znatno se razlikuju od okolne pozadine

Skup $\Gamma = \{x_1, \dots, x_n\}$ je skup svih piksela naše slike. Detekcija anomalije svodi se na pronalaženje podskupa piksela koji sadrži piksele anomalije na slici. Svakom pikselu pridružimo $\sqrt{p} \times \sqrt{p}$ kvadrat susjednih piksela transformiranih u vektor, čime je svaki piksel iz Γ oblika $x_i \in \mathbb{R}^p$. Svakom pikselu pridružimo ocjenu $C(x_i) \in [0, 1]$ takvu da pikseli iz pozadine imaju vrijednost blizu 0, a pikseli anomalije blizu 1.

2.2 Algoritam i implementacija

Rješavamo postavljeni problem koristeći difuzijska preslikavanja. Koristimo Gaussovu jezgru

$$w_{ij} = w(x_i, x_j) = \exp\left(\frac{-\|x_i - x_j\|^2}{\sigma_i \sigma_j}\right),$$

gdje su σ_i i σ_j lokalni parametri za x_i i x_j i ovise o susjednim elementima, $\sigma_i = \|x_i - x_K\|^2$, gdje je x_K K -ti najbliži susjed od x_i . Ovdje koristimo svojstvo da su pikseli anomalije izolirani i anomalije male, pa će udaljenost između piksela anomalije i K -tog najbližeg susjeda (koji je vrlo vjerojatno piksel pozadine) već biti velika, dok će udaljenost piksela pozadine i njegovog K -tog susjeda biti malena. Tako grupiramo piksele pozadine zajedno u guste klastere u novim koordinatama, dok su anomalni pikseli udaljeni od njih.

Dobivenu matricu $W = [w_{ij}]$ normaliziramo:

$$p_{ij} = \frac{w_{ij}}{\sum_{k=1}^n w_{ik}}$$

i tako dobijemo Markovljevu matricu prijelaza za naš skup podataka $P = [p_{ij}] \in \mathbb{R}^{n \times n}$.

Spektralnom dekompozicijom matrice P dobijemo lijeve i desne svojstvene vektore pridružene svojstvenim vrijednostima $1 = |\lambda_0| \geq |\lambda_1| \geq \dots$: t koraka Markovljeva lanca reprezentiranog s P se mogu prikazati kao

$$p_t(x, y) = \sum_{l \geq 0} \lambda_l^t \psi_l(x) \phi_l(y).$$

Uzmemo prvih l svojstvenih vektora, izostavljajući ψ_0 jer je konstantan i pridružen svojstvenoj vrijednosti 1. Difuzijsko preslikavanje za dani t definirano je kao

$$\Psi_t : x \rightarrow (\lambda_1^t(x), \dots, \lambda_l^t(x))^T.$$

Difuzijsku udaljenost dva elementa iz skupa podataka možemo dobiti kao euklidsku udaljenost njihovih difuzijskih preslikavanja: $D_t(x, y) = \|\Psi_t(x) - \Psi_t(y)\|$.

Računanje difuzijskog preslikavanja za čitavu matricu W nije efikasno, jer za naš algoritam koji radi na slikama formata $200 \times 200 = 40000$ piksela, matrica W je velika 40000×40000 - uz 8 bajtova po jednoj float vrijednosti, to je otprilike 1.6×10^9 bajtova samo za držanje cijele matrice u memoriji. Rješenje je izračunati preslikavanje samo za manji podskup podataka i nakon toga proširiti ga na ostale podatke. Implementirali smo Nyströmovu metodu za proširenje i tzv. Laplacian Pyramid metodu.

2.2.1 Nyströмова metoda za proširenje

Za dani podskup Γ' od m piksela i njihovih difuzijskih preslikavanja $\Psi(x_i) \in \mathbb{R}^{m \times d}$, za svaki novi piksel x_{novi} izvan podskupa, Nyströmovo proširenje mu pridružuje

$$\Psi(x_{novi}) = \frac{1}{\lambda_k} \sum_{j \in \Gamma'} \tilde{w}(x_{novi}, x_j) \cdot \psi_k(x_j),$$

dje je $\psi_k(x_j)$ k -ti svojstveni vektor difuzijskog preslikavanja za piksel x_j iz podskupa, λ_k odgovarajuća svojstvena vrijednost, a $\tilde{w}(x_{novi}, x_j)$ normalizirana vrijednost jezgre između novog piksela i piksela podskupa:

$$\tilde{w}(x_{novi}, x_j) = \frac{\exp\left(-\frac{\|x_{novi} - x_j\|^2}{\sigma_j^2}\right)}{\sum_{k \in \Gamma'} \exp\left(-\frac{\|x_{novi} - x_k\|^2}{\sigma_k^2}\right)}$$

2.2.2 Laplacian Pyramid metoda za proširenje

Problem s Nyströmovom metodom je to što koristi istu globalnu interpolaciju. U slučaju da funkcija preslikavanja na lokalnoj razini jako varira, taj pristup

neće uspješno uhvatiti sitne detalje. Kao alternativa predstavljena je Laplacian Pyramid metoda - prvotno se jezgra grubo aproksimira između svih parova u podskupu:

$$W_0 = w_o(x_i, x_j) = \exp(-\|x_i - x_j\|^2 / \epsilon_0),$$

s velikim ϵ_0 . Dobijemo operator zaglađivanja K_0 normalizacijom W_0 . Iterativno nastavljamo, gdje je na razini l ϵ_0 zamijenjen s $\epsilon_0/2^l$. Funkciju f , dano difuzijsko preslikavanje na našem podskupu predstavljamo iterativno u Laplacian Pyramid obliku s

$$s_0(x_k) = \sum_{i=1}^n k_0(x_i, x_k) f(x_i)$$

$$s_l(x_k) = \sum_{i=1}^n k_l(x_i, x_k) d_l(x_i),$$

gdje je

$$d_l(x_k) = f - \sum_{m=0}^{l-1} s_m.$$

Iteriramo dok razlika $\|f - \sum_k s_k\|$ ne padne ispod željene vrijednosti. Nakon toga, f se proširuje na novu točku x_{novi} koristeći $f(x_{novi}) = \sum_i s_i(x_{novi})$. Prednost ove metode je to što može proširiti jednostavne funkcije, koje će aproksimirati manjim brojem iteracija i složenije funkcije s više detalja, koje će zahtijevati više iteracija.

2.2.3 Uzorkovanje podskupa

Da bismo koristili metode za proširenje, moramo odlučiti na koji način uzorkovati podatke. Pošto su proširenja interpolacijske metode, ako u podskupu dobivenim uzorkovanjem ne obuhvatimo piksele anomalije, interpolacija neće moći pravilno proširiti vrijednosti na piksele anomalije. Pristup koji omogućava uzorkovanje većeg podskupa podataka i u isto vrijeme ne dovodi do prevelikog skupa podataka koje moramo obaditi je tzv. Multiscale metoda koja stvara tzv. Gaussovsku piramidu slika:

- Primjenjujemo Gaussov filter na reduciranu sliku kako bi zagladili sliku
- Uzimamo svaki drugi piksel slike u obje koordinate, time smanjujući obje dimenzije za faktor 2

Postupak ponavljamo dok ne dobijemo sliku dovoljno male rezolucije da možemo uzorkovati velik broj, ako ne i sve piksele slike najmanje rezolucije. Nakon toga ocijenimo sve piksele i ovisno o ocjeni, sumnjive (definirano kao 95-ti centil ocjena za tu razinu) ubacimo u podskup na idućoj, višoj razini piramide.

Ostatak podskupa na idućoj razini napunimo nasumično izabranim pikselima. Možemo uzorkovati manje omjere piksela što je slika finija, jer smo u grubljim razinama "ulovili" anomalije.

Pri računanju, kako bi osigurali da je matrica jezgre W izračunata na odabranom podskupu rijetka, računamo w samo za k najbližih susjeda, inače je $w(x_i, x_j) = 0$. Anomaly ocjena također se računa na najbližim pikselima. Za smanjenje složenosti, umjesto da računamo udaljenost u originalnom prostoru, računamo ju u difuzijskim koordinatama. Za dodatno smanjenje složenosti, umjesto računanja udaljenosti između svih ostalih piksela, koristimo svojstvo anomalija - gledamo samo prozor oko piksela. Dodatno, pošto očekujemo da su anomalije grupirane zajedno u malom području, zapravo gledamo prsten oko piksela, izbacujući piksele direktno pored promatranog piksela.

Računamo afinitete piksela koristeći difuzijske koordinate:

$$\bar{w}(i, j) = \exp(-\|\Psi(x_i) - \Psi(x_j)\|^2 / \bar{\sigma}),$$

gdje koristimo globalni $\bar{\sigma}$ kako bismo mogli prepoznati anomalije - očekujemo da globalni sigma prikazuje udaljenost u prosjeku cijele slike, dakle, pozadine. Računamo je odabirom n_{par} parova piksela i za svaki par računamo difuzijsku udaljenost. One predstavljaju prosječne udaljenosti piksela u slici. Empirijska varijanca tih udaljenosti je σ_{par}^2 . Postavimo $\bar{\sigma} = r\sigma_{par}^2$, gdje r određuje koliko bliske točke trebaju biti u difuzijskom prostoru.

Sad konačno za određivanje je li i -ti piksel anomalije koristimo ocjenu

$$C_l(i) = 1 - \frac{1}{m} \sum_{j \in N_i} \bar{w}(i, j),$$

gdje je N_i prsten piksela oko i -tog piksela. Koristimo prsten jer bi bez izbacivanja unutarnjeg dijela prozora oko piksela pikselu anomalije bila pridružena niska ocjena, jer se po pretpostavci u okolini piksela anomalije nalaze ostali pikseli anomalije.

2.2.4 Saliency Score

Uz ocjene iz [3], isprobali smo i Saliency score iz rada [4]. Za razliku od *anomaly score* ocjene koja mjeri koliko se piksel razlikuje od susjednih piksela, *saliency score* mjeri koliko je piksel rijedak u cijeloj slici. Ključna pretpostavka u ovom pristupu je to da su pikseli pozadine slični i susjednim i dalekim pikselima, dok su anomalije slične samo sebi susjednim pikselima.

Saliency score piksela definiramo kao:

$$S(i) = 1 - \exp \left[-\frac{1}{K} \sum_{k=1}^K d(p_i, p_k) \right],$$

gdje je p_i kvadrat piksela susjednih pikselu i , a $\{p_1, \dots, p_K\}$ K najbližih točaka u difuzijskom prostoru. Udaljenost $d(p_i, p_j)$ definiramo s:

$$d(p_i, p_j) = \frac{d_{DM}(p_i, p_j)/2\sigma_K}{1 + c * d_{position}(p_i, p_j)},$$

gdje je $d_{DM}(p_i, p_j)$ difuzijska udaljenost, $d_{position}(p_i, p_j)$ euklidska udaljenost pozicija kvadrata p_i i p_j u slici, normalizirana s najvećom dimenzijom slike, a σ_K standardna devijacija udaljenosti najbližih K kvadrata.

Uočimo da je udaljenost $d(p_i, p_j)$ proporcionalna difuzijskoj udaljenosti kvadrata i obrnuto proporcionalna euklidskoj udaljenosti pozicija kvadrata. Time postizemo da se utjecaj kvadrata p_j na *saliency score* smanjuje s njegovom udaljenosti od p_i . Dijeljenje sa $2\sigma_K$ otprilike skalira $d_{DM}(p_i, p_j)$ na interval $[0, 1]$ kako bi d_{DM} i $d_{position}$ bile usporedive veličine te postiže neovisnost o skali difuzijskih udaljenosti.

Saliency score ima tri glavne prednosti u odnosu na *anomaly score*, a to su:

- Manja osjetljivost na promjenu pozadine
- Nema pretpostavke o veličini anomalije
- Značajno manji broj hiperparametara


3 Non-Gaussian Background Extreme Value Analysis

Ovaj algoritam se temelji na Mahalanobisovoj udaljenosti. Njegova najveća prednost je što se može koristiti na hiperspektralnim slikama, ali i generalno u detekciji anomalija kod bilo kakvih vektorskih podataka koji ne moraju biti slike.

Mahalanobisova udaljenost podatka x od distribucije $\mathbf{P}$ s očekivanjem μ i kovarijacijskom matricom Σ definira se na sljedeći način:

$$d(x, \mathbf{P}) := \sqrt{(x - \mu)^T \Sigma^{-1} (x - \mu)}$$

Na donjoj slici simulirani su podaci iz bivarijantne normalne distribucije s očekivanjem $\mu = (0, 0)$ i kovarijacijskom matricom $\Sigma = \begin{bmatrix} 2 & 0 \\ 0 & 1 \end{bmatrix}$. Euklidska udaljenost crvene i plave točke od ishodišta je jednaka, no jasno je da je plava točka u kontekstu distribucije ekstremnija jer je varijanca u njenom smjeru manja i Mahalanobisova udaljenost to detektira pa tako plava točka ima udaljenost 2, a crvena 0.89



Slika 1: Usporedba euklidske i Mahalanobisove udaljenosti

Zanimljiv rezultat kaže da za uzorke iz normalne distribucije Mahalanobisova udaljenost slijedi χ^2 distribuciju. S obzirom da mi ne možemo pretpostaviti nor-

malnost naših podataka, pretpostavit ćemo da Mahalanobisova udaljenost slijeđi gama distribuciju koja je dosta općenita i može dobro aproksimirati mnoge distribucije te je χ^2 distribucija njen poseban slučaj.

Ideja algoritma je iterativno računati Mahalanobisove udaljenosti svih podataka (u našem slučaju piksela) pomoću procijenjenih očekivanja i kovarijacijske matrice te potom izbaciti one podatke čija je udaljenost veća od nekog praga u skup anomalija i sve ponoviti na "čišćem" skupu sve dok više nema podataka za izbacivanje ili ih ima jako malo.

Tablica 1: NG BEVA

Ulazni podaci: $In = \{m x_m \in C\}, x_m : [p \times 1]$	
Inicijalizacija: $A_C^0 = \emptyset, B_C^0 = In$	
Glavna petlja:	
1. Procijeni očekivanje μ_C^i i kovarijacijsku matricu Σ_C^i podataka u B_C^i	
2. Izračunaj Mahalanobisove udaljenosti vektora u B_C^i od njihove distribucije:	
$\forall x_m \in B_C^i : d_m = \sqrt{(x_m - \mu_C^i)^t (\Sigma_C^i)^{-1} (x_m - \mu_C^i)}$	
3. Metodom maksimalne vjerodostojnosti procijeni parametre gama distribucije za Mahalanobisove udaljenosti izračunate u 2	
4. Izbaci ekstremne točke u skup anomalija	
$\delta = \{x_m \in B_C^i d_m \geq \tau^i\}$	
$B_C^{i+1} = B_C^i \setminus \delta$	
$A_C^{i+1} = A_C^i \cup \delta$	
5. Provjeri kriterij zaustavljanja.	
Izlazni podaci: $A_C = A_C^i$ skup anomalija, $B_C = B_C^i$ pozadina	

Gornja tablica ostavlja sljedeća pitanja otvorenima: Kako dobro procijeniti očekivanje i kovarijacijsku matricu u prvom koraku, kako odrediti prag τ^i u četvrtom koraku i konačno koji je kriterij zaustavljanja u petom koraku.

Iako je općenito moguće procijeniti očekivanje kao običan prosjek vektora i kovarijacijsku matricu kao $\frac{1}{N}XX^T$ gdje je X centrirana matrica podataka, Maha-

lanobisova udaljenost je povezana s robusnijim procjeniteljem za očekivanje i kovarijacijsku matricu koji u obzir uzima upravo tu udaljenost podataka tako da udaljeniji podaci utječu manje, a bliži više na procjenu:

$$\mu_C^i = \frac{\sum_{x_m \in B_C^i} \omega_m^i x_m}{\sum_{x_m \in B_C^i} \omega_m^i}$$

$$\Sigma_C^i = \frac{\sum_{x_m \in B_C^i} (\omega_m^i)^2 (x_m - \mu_C^i)^T (x_m - \mu_C^i)}{\sum_{x_m \in B_C^i} (\omega_m^i)^2 - 1}$$

$$\omega_m^{i+1} = \begin{cases} 1, & \text{if } d_m \leq d_0, \\ \frac{d_0}{d_m} \exp\left(-\frac{1}{2} \frac{(d_m - d_0)^2}{\gamma^2}\right), & \text{if } d_m \geq d_0. \end{cases}$$


Dakle u svakoj iteraciji trebamo još izračunati i težine ω^i na temelju prethodnih Mahalanobisovih udaljenosti.

Što se praga τ^i tiče, njega je najlakše odrediti percentilnom metodom tj. odbacivati kao anomalije sve one podatke koji su veći od nekog visokog kvantila procijenjene distribucije. Takva metoda oponaša postupak kod statističkog testa.

Kriterij zaustavljanja može biti da je postotak piksela klasificiranih kao anomalija manji od neke tolerancije.

Ovdje valja napomenuti da s obzirom da se algoritam svodi na promatranje koliko pojedini dijelovi odudaraju od prosjeka, ako imamo više klastera podataka (npr. radikalno različiti dijelovi slike) onda je svakako dobro prvo klasterirati podatke (mi smo to radili spektralnim klasteriranjem). Klasteriranjem anomalije završe u nekom klasteru kojem su najslićnije i onda se otkrivaju i izdvajaju objašnjenim algoritmom.

Iako mi nismo imali hiperspektralne slike, već crno-bijele slike dobivene sonarom, htjeli smo isprobati neki sličan statistički pristup. Stoga smo prilagodili NG-BEVA algoritam na način da smo svakom pikselu pridružili još dvije vrijednosti: prosjek vrijednosti piksela u $p \times p$ okolini te standardnu devijaciju tih vrijednosti. Time smo dobili, ne baš hiperspektralne, ali barem višedimenzionalne podatke, koji na neki način opisuju piksel i "teksturu" njegove okoline. Kao što ćemo pokazati, ovaj algoritam je pokazao neke obećavajuće rezultate, ali se pokazao jako osjetljivim na hiperparametere (pogotovo izbor kvantila za odbacivanje).



Slika 2: **Detekcije potopljenih brodova s NG-BEVA algoritmom**
 Stupci redom sadrže: originalnu 200×200 sliku, heatmap Mahalanobisovih udaljenosti, područje određeno kao anomalija i anomalije prikazane na originalnoj slici.

4 Rezultati i usporedba algoritama


Usporedili smo navedene algoritme na tri skupa podataka: slike morskih mina dobivene side-scan sonarom, slike potopljenih brodova s dna mora i satelitske slike brodova na moru. Napomenimo da ovi skupovi podataka imaju vrlo različite karakteristike: morske mine su relativno male anomalije na šumovitim slikama, potopljeni brodovi su velike anomalije koje čine oko 20% slike, dok su brodovi male anomalije koje se jako ističu od pozadine.

Nakon izvršenja algoritama sve smo detekcije dodatno obradili tako što smo, analogno postupku u [3], uklonili sve detekcije manje od 10 piksela.


Za početak pogledajmo kako izgledaju detektirane anomalije na nekim primjerima slika 3, 4 i 5.

Tablica 2: **Skupovi podataka** Broj slika i broj anomalija po skupu podataka.


Podaci	Veličina slike	Broj slika	Broj anomalija
Ships	200×200	3	4
Shipwrecks	200×200	5	5
Mines	168×168	12	13




Slika 3: **Detekcija brodova** Vidimo kako je Laplacian anomaly algoritam uspješno detektirao brodove, iako su područja dosta široka. Laplacian saliency je također detektirao brodove, ali uz više lažnih detekcija, dok je NG-BEVA detektirao rubove brodova.



Slika 4: **Detekcija potopljenog broda** Na ovom primjeru su Laplacian saliency i NG-BEVA radili gotovo jednako dobro, dok je Laplacian anomaly dao veliki broj lažnih detekcija. No, taj rezultat je i očekivan zbog pretpostavke *anomaly score-a* da su anomalije male u odnosu na sliku.



Slika 5: **Detekcija mina** Na ovom primjeru Laplacian anomaly i NG-BEVA su detektirali minu, no sva tri algoritma su imala problem s lažnim detekcijama. Veliki je problem, pogotovo za Laplacian algoritme, tzv. područje nadira uz desni rub slike.



Slika 6: **Detekcija mina s Nyström Saliency score algoritmom** Prikazano je pet slika morskih mina s detektiranim područjem.

4.1 Analiza algoritama

Kako bi mogli uspoređivati algoritme za detekciju anomalije prvo moramo odrediti metodologiju i metrike za uspoređivanje. Ukratko, metoda će biti dobra ako detektira visoki postotak anomalija s dobrom pokrivenosti i malim brojem krivih detekcija.

Stoga, mi smo proučili nekoliko mjera kvalitete detekcije. Prvo smo proučili standardne mjere kvalitete klasifikacije na razini piksela (*precision*, *recall*, *f1 score*), što nam daje mjeru o pokrivenosti anomalija. Zatim smo proučavali slične mjere na razini anomalija, gdje, kao u [2], smatramo da je anomalija detektirana ako je barem jedan njen piksel označen kao sumnjiv. Krivim detekcijama smatramo sve komponente koje ne dodiruju niti jednu anomaliju. Ovakav kriterij je prikladan za situacije poput detekcije morskih mina gdje nam je važnije odrediti barem jedan piksel anomalije, nego pokriti cijelu anomaliju.

Tablica 3: **Metrike na razini piksela** Stupci redom predstavljaju: prosječni *Average precision* po slikama, sveukupni *f1* na svim slikama, prosječni *f1* po slikama, sveukupni *precision* te sveukupni *recall*.

Algoritam	Prosječni AP	f1	Prosječni f1	Precision	Recall
<i>Ships (200×200)</i>					
Nyström anomaly	0.171	0.150	0.123	0.081	1.000
Nyström saliency	0.076	0.057	0.045	0.032	0.271
Laplacian anomaly	0.088	0.125	0.098	0.068	0.822
Laplacian saliency	0.071	0.081	0.058	0.044	0.455
NG-BEVA	0.329	0.051	0.048	0.041	0.068
<i>Shipwrecks (200×200)</i>					
Nyström anomaly	0.492	0.210	0.202	0.839	0.120
Nyström saliency	0.561	0.246	0.275	0.880	0.143
Laplacian anomaly	0.655	0.305	0.329	0.760	0.191
Laplacian saliency	0.628	0.303	0.332	0.860	0.184
NG-BEVA	0.497	0.369	0.391	0.859	0.235
<i>Mines (168×168)</i>					
Nyström anomaly	0.057	0.112	0.123	0.073	0.233
Nyström saliency	0.081	0.207	0.231	0.147	0.353
Laplacian anomaly	0.050	0.061	0.061	0.038	0.163
Laplacian saliency	0.054	0.096	0.097	0.060	0.242
NG-BEVA	0.296	0.221	0.228	0.145	0.461

Na tablici 3 vidimo metrike na razini piksela. Algoritmi su najbolje rezultate postigli na slikama potopljenih brodova, a najgore na satelitskim slikama brodova. Fokusirajući se na slike morskih mina, uočimo da je *precision* za sve algoritme manji od 0.15 što ukazuje na veliki broj krivih detekcija, a *recall* u rasponu (0.15, 0.47) ukazuje na relativno malu pokrivenost anomalija.

Tablica 4: **Detekcija anomalija** Stupci redom označavaju: broj detektiranih anomalija, broj ne detektiranih anomalija, vjerojatnost detekcije te prosječnu pokrivenost anomalije.

Algoritam	Detektirano	Promašeno	P(D) (%)	Prosječna pokrivenost (%)
<i>Ships</i> (200×200)				
Nyström anomaly	4	0	100.0	100.0
Nyström saliency	3	1	75.0	71.4
Laplacian anomaly	3	1	75.0	83.2
Laplacian saliency	3	1	75.0	14.6
NG-BEVA	3	1	75.0	36.9
<i>Shipwrecks</i> (200×200)				
Nyström anomaly	5	0	100.0	11.9
Nyström saliency	5	0	100.0	17.5
Laplacian anomaly	5	0	100.0	21.5
Laplacian saliency	5	0	100.0	21.5
NG-BEVA	5	0	100.0	26.9
<i>Mines</i> (168×168)				
Nyström anomaly	11	2	84.6	24.1
Nyström saliency	13	0	100.0	38.1
Laplacian anomaly	9	4	69.2	16.0
Laplacian saliency	13	0	100.0	25.1
NG-BEVA	13	0	100.0	49.7

Na tablici 4 vidimo koliko su algoritmi uspješni u detekciji anomalija. Također, čini se da je *saliency score* na svim podacima bio barem jednako uspješan ili uspješniji od *anomaly score-a*, a Nyström proširenje jednako uspješno ili uspješnije od Laplace proširenja. Napomenimo da, iako anomaliju smatramo detektiranom ako smo detektirali samo jedan njen piksel, prosječna pokrivenost anomalija je barem 10% za sve algoritme.

Pogledajmo detaljnije podatke o krivim detekcijama u tablici 5. Vidimo da Nyström metode u pravilu daju najmanje krivih detekcija, dok naša inačica NG-BEVA, iako u satelitskim slikama brodova postiže jako dobre rezultate, na podacima iz sonara daje iznimno puno krivih detekcija. U zadnjem stupcu vidimo da slike morskih mina imaju značajno veću učestalost krivih detekcija, što je i očekivano jer ti podaci sadrže puno više nepravilnosti od preostala dva skupa podataka.


Tablice 4 i 5 daju naslutiti da Nyström metode daju najbolje rezultate na testiranim podacima, a to možemo vidjeti i po statistikama u tablici 6. Vidimo da Nyström metode imaju najbolje rezultate u smislu *precision*, *recall* i *f1* mjera, s iznimkom satelitskih slika brodova gdje je NG-BEVA najbolji. Ipak, u ostalim podacima NG-BEVA daje najgore rezultate što bi se moglo objasniti primjednom da je naša inačica NG-BEVA algoritma jako osjetljiva na promjene

Tablica 5: **Statistike krivih detekcija** Stupci redom označavaju: broj sumnjivih komponenti na svim slikama, broj krivih detekcija na svim slikama, prosječni broj krivih detekcija (FA) po slici te prosječni broj krivih detekcija na milijun piksela.

Algoritam	Sumnjive komponente	Krive detekcije	FA/Slika	FA/MPix
<i>Ships</i> (200×200)				
Nyström anomaly	12	8	2.67	66.7
Nyström saliency	34	31	10.33	258.3
Laplacian anomaly	56	53	17.67	441.7
Laplacian saliency	59	56	18.67	466.7
NG-BEVA	4	1	0.33	8.3
<i>Shipwrecks</i> (200×200)				
Nyström anomaly	42	11	2.20	55.0
Nyström saliency	47	11	2.20	55.0
Laplacian anomaly	68	28	5.60	140.0
Laplacian saliency	69	13	2.60	65.0
NG-BEVA	118	58	11.60	290.0
<i>Mines</i> (168×168)				
Nyström anomaly	74	62	5.17	183.1
Nyström saliency	92	77	6.42	227.3
Laplacian anomaly	108	93	7.75	274.6
Laplacian saliency	118	99	8.25	292.3
NG-BEVA	317	296	24.67	874.0

Tablica 6: **Metrike na razini anomalija**

Algoritam	Precision	Recall	f1
<i>Ships</i> (200×200)			
Nyström anomaly	0.333	1.000	0.500
Nyström saliency	0.088	0.750	0.158
Laplacian anomaly	0.054	0.750	0.100
Laplacian saliency	0.051	0.750	0.095
NG-BEVA	0.750	0.750	0.750
<i>Shipwrecks</i> (200×200)			
Nyström anomaly	0.312	1.000	0.476
Nyström saliency	0.312	1.000	0.476
Laplacian anomaly	0.152	1.000	0.263
Laplacian saliency	0.278	1.000	0.435
NG-BEVA	0.079	1.000	0.147
<i>Mines</i> (168×168)			
Nyström anomaly	0.151	0.846	0.256
Nyström saliency	0.144	1.000	0.252
Laplacian anomaly	0.088	0.692	0.157
Laplacian saliency	0.116	1.000	0.208
NG-BEVA	0.042	1.000	0.081



Slika 7: **Detekcije potopljenih brodova s Laplacian Anomaly score algoritmom** Stupci redom sadrže: originalnu 200×200 sliku, *anomaly score* heatmap, područje određeno kao anomalija i anomalije prikazane na originalnoj slici.

hiperparametara. Čini nam se da bi sofisticiraniji izbor granice mogao značajno poboljšati algoritam.

Pomalo je iznenađujuća uspješnost algoritama na slikama potopljenih brodova, s obzirom da one imaju velike anomalije koje pokrivaju veliki dio slike. No, kako smo detekciju smatrali uspješnom ako smo detektirali barem jedan piksel anomalije, logično je da ćemo lakše detektirati anomaliju kada ona čini 20% slike. Iz tog razloga, usporedili smo i vjerojatnost detekcije ako definiramo točnu detekciju kao 50% pokrivenosti anomalije. Kao što možemo vidjeti u tablici 7 Nyström saliency i Laplacian anomaly algoritmi su detektirali 40% anomalija na ovaj način, Laplacian saliency 20%, a ostali nisu detektirali niti jednu anomaliju s barem 50% pokrivenosti. Jedan mogući razlog zašto su ovi algoritmi uspjeli detektirati velike anomalije je taj što je tekstura potopljenog broda jako varijabilna, pa svaki dio broda djeluje kao anomalija.

Tablica 7: **Detekcija anomalija s 50% pokrivenosti**

Algoritam	Detektirano	Promašeno	P(D) (%)	Prosječna pokrivenost (%)
Nyström saliency	2	3	40.0	0.333
Nyström anomaly	0	5	0.0	0.247
Laplacian saliency	1	4	20.0	0.397
Laplacian anomaly	2	3	40.0	0.392
NG-BEVA	0	5	0.0	0.284

4.2 Usporedba brzine algoritama

Za kraj usporedimo brzine izvršavanja algoritama. Na tablici 8 vidimo statistike vremena izvršavanja algoritama po skupu podataka i algoritmu. Laplacian algoritmi su očekivano najsporiji (3 puta sporiji od Nyström algoritama), dok je NG-BEVA daleko najbrži. Također, *saliency score* algoritmi su 10-20% brži od pripadnih algoritama s *anomaly score* ocjenom.

Tablica 8: **Rastav brzina po podacima i algoritmu**

Algoritam	n	Prosjek	Std. dev.	Medijan	Min	Max
<i>Ships</i> (200×200)						
Laplacian anomaly	3	65.40	1.33	64.97	64.34	66.90
Laplacian saliency	3	61.16	0.97	61.26	60.15	62.08
Nyström anomaly	3	20.83	0.49	21.06	20.27	21.15
Nyström saliency	3	16.12	0.94	16.21	15.13	17.00
NG-BEVA	3	2.87	0.57	2.69	2.42	3.52
<i>Shipwrecks</i> (200×200)						
Laplacian anomaly	5	65.37	0.70	65.75	64.45	66.10
Laplacian saliency	5	59.47	0.78	59.58	58.21	60.37
Nyström anomaly	5	20.59	0.54	20.30	20.16	21.45
Nyström saliency	5	15.04	0.51	15.07	14.34	15.67
NG-BEVA	5	3.79	1.12	3.26	2.76	5.60
<i>Mines</i> (168×168)						
Laplacian anomaly	12	34.78	0.70	34.86	32.74	35.38
Laplacian saliency	12	29.36	0.43	29.29	28.78	30.17
Nyström anomaly	12	10.60	0.24	10.56	10.29	11.20
Nyström saliency	12	7.89	0.29	7.94	7.33	8.19
NG-BEVA	12	2.48	0.22	2.42	2.29	2.84

5 Zaključak

U ovom smo radu demonstrirali učinkovitost četiri algoritama za detekciju anomalija u slikama. Pokazalo se da su algoritmi bazirani na difuzijskim preslikavanjima dali bolje rezultate od statističkog pristupa, iako je on dao obećavajuće rezultate te bi se mogao daljnje poboljšati.

Literatura

- [1] Charless Fowlkes, Serge Belongie, Fan Chung, and Jitendra Malik. Spectral grouping using the nyström method. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 26(2):214–225, 2004.
- [2] Eyal Madar, David Malah, and Meir Barzohar. Non-gaussian background modeling for anomaly detection in hyperspectral images. In *2011 19th European Signal Processing Conference*, pages 1125–1129, 2011.
- [3] Gal Mishne and Israel Cohen. Multiscale anomaly detection using diffusion maps. *IEEE Journal of Selected Topics in Signal Processing*, 7(1):111–123, 2013.
- [4] Gal Mishne and Israel Cohen. Multiscale anomaly detection using diffusion maps and saliency score. In *2014 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*, pages 2823–2827, 2014.