

Detekcija anomalija u slikama

Nikola Mamić, Jakov Tušek, Petar Matejčić

- Detekcija anomalija u slikama
 - Hiperspektralne slike, detekcija melanoma, kontrola kvalitete

- Detekcija anomalija u slikama
 - Hiperspektralne slike, detekcija melanoma, kontrola kvalitete
- Visko dimenzionalni podaci → redukcija dimenzije

- Detekcija anomalija u slikama
 - Hiperspektralne slike, detekcija melanoma, kontrola kvalitete
- Visko dimenzionalni podaci → redukcija dimenzije
- Odvajanje anomalija od pozadine

Problem

- Detekcija anomalija u slikama
 - Hiperspektralne slike, detekcija melanoma, kontrola kvalitete
- Visko dimenzionalni podaci → redukcija dimenzije
- Odvajanje anomalija od pozadine
- Ne možemo raditi na cijelim slikama

- Detekcija anomalija u slikama
 - Hiperspektralne slike, detekcija melanoma, kontrola kvalitete
- Visko dimenzionalni podaci → redukcija dimenzije
- Odvajanje anomalija od pozadine
- Ne možemo raditi na cijelim slikama
- ⇒ Nasumični uzorak piksela

- Detekcija anomalija u slikama
 - Hiperspektralne slike, detekcija melanoma, kontrola kvalitete
- Visko dimenzionalni podaci → redukcija dimenzije
- Odvajanje anomalija od pozadine
- Ne možemo raditi na cijelim slikama
- ⇒ Nasumični uzorak piksela
- Interpolacija ostalih vrijednosti

- Detekcija anomalija u slikama
 - Hiperspektralne slike, detekcija melanoma, kontrola kvalitete
- Visko dimenzionalni podaci → redukcija dimenzije
- Odvajanje anomalija od pozadine
- Ne možemo raditi na cijelim slikama
- ⇒ Nasumični uzorak piksela
- Interpolacija ostalih vrijednosti
- Statistički pristup

- Pretpostavke o anomalijama:
 - Anomalije su veće od jednog piksela
 - Vrlo su male, pozadina dominira i formira gust klaster
 - Znatno se razlikuju od okolne pozadine

- Pretpostavke o anomalijama:
 - Anomalije su veće od jednog piksela
 - Vrlo su male, pozadina dominira i formira gust klaster
 - Znatno se razlikuju od okolne pozadine
- Tražimo podskup piksela koji čine anomaliju

- Pretpostavke o anomalijama:
 - Anomalije su veće od jednog piksela
 - Vrlo su male, pozadina dominira i formira gust klaster
 - Znatno se razlikuju od okolne pozadine
- Tražimo podskup piksela koji čine anomaliju
- Svakom pikselu $x_i \in \mathbb{R}^p$ pridružimo $\sqrt{p} \times \sqrt{p}$ kvadrat okolnih piksela

- Pretpostavke o anomalijama:
 - Anomalije su veće od jednog piksela
 - Vrlo su male, pozadina dominira i formira gust klaster
 - Znatno se razlikuju od okolne pozadine
- Tražimo podskup piksela koji čine anomaliju
- Svakom pikselu $x_i \in \mathbb{R}^p$ pridružimo $\sqrt{p} \times \sqrt{p}$ kvadrat okolnih piksela
- Svakom pikselu pridružimo ocjenu $C(x_i) \in [0, 1]$

$$w_{ij} = w(x_i, x_j) = \exp \left(\frac{-\|x_i - x_j\|^2}{\sigma_i \sigma_j} \right)$$

$$w_{ij} = w(x_i, x_j) = \exp \left(\frac{-\|x_i - x_j\|^2}{\sigma_i \sigma_j} \right)$$

$$p_{ij} = \frac{w_{ij}}{\sum_{k=1}^n w_{ik}}$$

$$w_{ij} = w(x_i, x_j) = \exp \left(\frac{-\|x_i - x_j\|^2}{\sigma_i \sigma_j} \right)$$

$$p_{ij} = \frac{w_{ij}}{\sum_{k=1}^n w_{ik}}$$

$$p_t(x, y) = \sum_{l \geq 0} \lambda_l^t \psi_l(x) \phi_l(y)$$

$$w_{ij} = w(x_i, x_j) = \exp \left(\frac{-\|x_i - x_j\|^2}{\sigma_i \sigma_j} \right)$$

$$p_{ij} = \frac{w_{ij}}{\sum_{k=1}^n w_{ik}}$$

$$p_t(x, y) = \sum_{l \geq 0} \lambda_l^t \psi_l(x) \phi_l(y)$$

$$\Psi_t : x \rightarrow (\lambda_1^t(x), \dots, \lambda_l^t(x))^T \rightsquigarrow D_t(x, y) = \|\Psi_t(x) - \Psi_t(y)\|$$

$$w_{ij} = w(x_i, x_j) = \exp \left(\frac{-\|x_i - x_j\|^2}{\sigma_i \sigma_j} \right)$$

$$p_{ij} = \frac{w_{ij}}{\sum_{k=1}^n w_{ik}}$$

$$p_t(x, y) = \sum_{l \geq 0} \lambda_l^t \psi_l(x) \phi_l(y)$$

$$\Psi_t : x \rightarrow (\lambda_1^t(x), \dots, \lambda_l^t(x))^T \rightsquigarrow D_t(x, y) = \|\Psi_t(x) - \Psi_t(y)\|$$

- Izračunamo za podskup podataka $\rightarrow$ proširimo na ostale

$$\Psi(x_{novi}) = \frac{1}{\lambda_k} \sum_{j \in \Gamma'} \tilde{W}(x_{novi}, x_j) \cdot \psi_k(x_j),$$

$$\Psi(x_{novi}) = \frac{1}{\lambda_k} \sum_{j \in \Gamma'} \tilde{W}(x_{novi}, x_j) \cdot \psi_k(x_j),$$

$$\tilde{W}(x_{novi}, x_j) = \frac{\exp\left(-\frac{\|x_{novi} - x_j\|^2}{\sigma_j^2}\right)}{\sum_{k \in \Gamma'} \exp\left(-\frac{\|x_{novi} - x_k\|^2}{\sigma_k^2}\right)}$$

$$W_0 = w_0(x_i, x_j) = \exp(-\|x_i - x_j\|^2 / \epsilon_0),$$

$$W_0 = w_0(x_i, x_j) = \exp(-\|x_i - x_j\|^2 / \epsilon_0),$$

$$s_0(x_k) = \sum_{i=1}^n k_0(x_i, x_k) f(x_i)$$

$$s_l(x_k) = \sum_{i=1}^n k_l(x_i, x_k) d_l(x_i),$$

$$W_0 = w_0(x_i, x_j) = \exp(-\|x_i - x_j\|^2 / \epsilon_0),$$

$$s_0(x_k) = \sum_{i=1}^n k_0(x_i, x_k) f(x_i)$$

$$s_l(x_k) = \sum_{i=1}^n k_l(x_i, x_k) d_l(x_i),$$

$$d_l(x_k) = f - \sum_{m=0}^{l-1} s_m.$$

$$W_0 = w_0(x_i, x_j) = \exp(-\|x_i - x_j\|^2 / \epsilon_0),$$

$$s_0(x_k) = \sum_{i=1}^n k_0(x_i, x_k) f(x_i)$$

$$s_l(x_k) = \sum_{i=1}^n k_l(x_i, x_k) d_l(x_i),$$

$$d_l(x_k) = f - \sum_{m=0}^{l-1} s_m.$$

- Iteriramo dok $\|f - \sum_k s_k\|$ ne padne ispod određene razine

- Proširenje interpolacijsko → ne ćemo moći detektirati anomaliju ako ona nije u odabranom podskupu

Uzorkovanje podskupa piksela

- Proširenje interpolacijsko → ne ćemo moći detektirati anomaliju ako ona nije u odabranom podskupu
- Jedno rješenje: Multiscale metoda

- Proširenje interpolacijsko → ne ćemo moći detektirati anomaliju ako ona nije u odabranom podskupu
- Jedno rješenje: Multiscale metoda

Multiscale metoda:

- Primjenjujemo Gaussov filter na reduciranu sliku kako bi zagladili sliku
- Uzimamo svaki drugi piksel slike u obje koordinate, time smanjujući obje dimenzije za faktor 2

- w računamo samo s k najbližih susjeda $\rightarrow$ osigurano da je W rijetka matrica

- w računamo samo s k najbližih susjeda $\rightarrow$ osigurano da je W rijetka matrica
- Anomaly ocjenu računamo na k najbližih susjeda u difuzijskim koordinatama (prsten oko piksela)

- w računamo samo s k najbližih susjeda $\rightarrow$ osigurano da je W rijetka matrica
- Anomaly ocjenu računamo na k najbližih susjeda u difuzijskim koordinatama (prsten oko piksela)

$$\bar{w}(i, j) = \exp(-\|\Psi(x_i) - \Psi(x_j)\|^2 / \bar{\sigma}),$$

- w računamo samo s k najbližih susjeda $\rightarrow$ osigurano da je W rijetka matrica
- Anomaly ocjenu računamo na k najbližih susjeda u difuzijskim koordinatama (prsten oko piksela)

$$\bar{w}(i, j) = \exp(-\|\Psi(x_i) - \Psi(x_j)\|^2 / \bar{\sigma}),$$

$$C_l(i) = 1 - \frac{1}{m} \sum_{j \in N_i} \bar{w}(i, j),$$

$$S(i) = 1 - \exp \left[- \frac{1}{K} \sum_{k=1}^K d(p_i, p_k) \right],$$

$$S(i) = 1 - \exp \left[- \frac{1}{K} \sum_{k=1}^K d(p_i, p_k) \right],$$

$$d(p_i, p_j) = \frac{d_{DM}(p_i, p_j)/2\sigma_K}{1 + c * d_{position}(p_i, p_j)},$$

$$S(i) = 1 - \exp \left[- \frac{1}{K} \sum_{k=1}^K d(p_i, p_k) \right],$$

$$d(p_i, p_j) = \frac{d_{DM}(p_i, p_j)/2\sigma_K}{1 + c * d_{position}(p_i, p_j)},$$

Prednosti u odnosu na anomaly score:

$$S(i) = 1 - \exp \left[- \frac{1}{K} \sum_{k=1}^K d(p_i, p_k) \right],$$

$$d(p_i, p_j) = \frac{d_{DM}(p_i, p_j)/2\sigma_K}{1 + c * d_{position}(p_i, p_j)},$$

Prednosti u odnosu na anomaly score:

- Manja osjetljivost na promjenu pozadine

$$S(i) = 1 - \exp \left[- \frac{1}{K} \sum_{k=1}^K d(p_i, p_k) \right],$$

$$d(p_i, p_j) = \frac{d_{DM}(p_i, p_j)/2\sigma_K}{1 + c * d_{position}(p_i, p_j)},$$

Prednosti u odnosu na anomaly score:

- Manja osjetljivost na promjenu pozadine
- Nema pretpostavke o veličini anomalije

$$S(i) = 1 - \exp \left[- \frac{1}{K} \sum_{k=1}^K d(p_i, p_k) \right],$$


$$d(p_i, p_j) = \frac{d_{DM}(p_i, p_j)/2\sigma_K}{1 + c * d_{position}(p_i, p_j)},$$

Prednosti u odnosu na anomaly score:

- Manja osjetljivost na promjenu pozadine
- Nema pretpostavke o veličini anomalije
- Značajno manji broj hiperparametara

Statistički pristup - Mahalanobisova udaljenost

$$d(x, P) := \sqrt{(x - \mu)^T \Sigma^{-1} (x - \mu)}$$



Non-Gaussian Background Extreme Value Analysis

Ulazni podaci: $ln = \{m | x_m \in C\}, x_m : [p \times 1]$

Inicijalizacija: $A_C^0 = \emptyset, B_C^0 = ln$

Glavna petlja:

1. Procijeni očekivanje μ_C^i i kovarijacijsku matricu Σ_C^i podataka u B_C^i
2. Izračunaj Mahalanobisove udaljenosti vektora u B_C^i od njihove distribucije:

$$\forall x_m \in B_C^i : d_m = \sqrt{(x_m - \mu_C^i)^t (\Sigma_C^i)^{-1} (x_m - \mu_C^i)}$$

4. Metodom maksimalne vjerodostojnosti procijeni parametre gama distribucije za Mahalanobiusove udaljenosti izračunate u 2
5. Izbaci ekstremne točke u skup anomalija

$$\delta = \{x_m \in B_C^i | d_m \geq \tau^i\}$$

$$B_C^{i+1} = B_C^i \setminus \delta$$

$$A_C^{i+1} = A_C^i \cup \delta$$

6. Provjeri kriterij zaustavljanja.

Izlazni podaci: $A_C = A_C^i$ skup anomalija , $B_C = B_C^i$ pozadina

$$\mu_C^i = \frac{\sum_{x_m \in B_C^i} \omega_m^i x_m}{\sum_{x_m \in B_C^i} \omega_m^i}$$

Non-Gaussian Background Extreme Value Analysis

$$\mu_C^i = \frac{\sum_{x_m \in B_C^i} \omega_m^i x_m}{\sum_{x_m \in B_C^i} \omega_m^i}$$

$$\Sigma_C^i = \frac{\sum_{x_m \in B_C^i} (\omega_m^i)^2 (x_m - \mu_C^i)^T (x_m - \mu_C^i)}{\sum_{x_m \in B_C^i} (\omega_m^i)^2 - 1}$$




Non-Gaussian Background Extreme Value Analysis

$$\mu_C^i = \frac{\sum_{x_m \in B_C^i} \omega_m^i x_m}{\sum_{x_m \in B_C^i} \omega_m^i}$$

$$\Sigma_C^i = \frac{\sum_{x_m \in B_C^i} (\omega_m^i)^2 (x_m - \mu_C^i)^T (x_m - \mu_C^i)}{\sum_{x_m \in B_C^i} (\omega_m^i)^2 - 1}$$

$$\omega_m^{i+1} = \begin{cases} 1, & \text{if } d_m \leq d_0, \\ \frac{d_0}{d_m} \exp\left(-\frac{1}{2} \frac{(d_m - d_0)^2}{\gamma^2}\right), & \text{if } d_m \geq d_0. \end{cases}$$

Primjeri detekcije



Metrike na razni piksela

Algoritam	Prosječni AP	f1	Prosječni f1	Precision	Recall
<i>Ships (200×200)</i>					
Nyström anomaly	0.171	0.150	0.123	0.081	1.000
Nyström saliency	0.076	0.057	0.045	0.032	0.271
Laplacian anomaly	0.088	0.125	0.098	0.068	0.822
Laplacian saliency	0.071	0.081	0.058	0.044	0.455
NG-BEVA	0.329	0.051	0.048	0.041	0.068
<i>Shipwrecks (200×200)</i>					
Nyström anomaly	0.492	0.210	0.202	0.839	0.120
Nyström saliency	0.561	0.246	0.275	0.880	0.143
Laplacian anomaly	0.655	0.305	0.329	0.760	0.191
Laplacian saliency	0.628	0.303	0.332	0.860	0.184
NG-BEVA	0.497	0.369	0.391	0.859	0.235
<i>Mines (168×168)</i>					
Nyström anomaly	0.057	0.112	0.123	0.073	0.233
Nyström saliency	0.081	0.207	0.231	0.147	0.353
Laplacian anomaly	0.050	0.061	0.061	0.038	0.163
Laplacian saliency	0.054	0.096	0.097	0.060	0.242
NG-BEVA	0.296	0.221	0.228	0.145	0.461

Detekcija anomalija

Algoritam	Detektirano	Promašeno	P(D) (%)	Prosječna pokrivenost (%)
<i>Ships (200×200)</i>				
Nyström anomaly	4	0	100.0	100.0
Nyström saliency	3	1	75.0	71.4
Laplacian anomaly	3	1	75.0	83.2
Laplacian saliency	3	1	75.0	14.6
NG-BEVA	3	1	75.0	36.9
<i>Shipwrecks (200×200)</i>				
Nyström anomaly	5	0	100.0	11.9
Nyström saliency	5	0	100.0	17.5
Laplacian anomaly	5	0	100.0	21.5
Laplacian saliency	5	0	100.0	21.5
NG-BEVA	5	0	100.0	26.9
<i>Mines (168×168)</i>				
Nyström anomaly	11	2	84.6	24.1
Nyström saliency	13	0	100.0	38.1
Laplacian anomaly	9	4	69.2	16.0
Laplacian saliency	13	0	100.0	25.1
NG-BEVA	13	0	100.0	49.7

Metrike na razini anomalija

Algoritam	Precision	Recall	f1
<i>Ships (200×200)</i>			
Nyström anomaly	0.333	1.000	0.500
Nyström saliency	0.088	0.750	0.158
Laplacian anomaly	0.054	0.750	0.100
Laplacian saliency	0.051	0.750	0.095
NG-BEVA	0.750	0.750	0.750
<i>Shipwrecks (200×200)</i>			
Nyström anomaly	0.312	1.000	0.476
Nyström saliency	0.312	1.000	0.476
Laplacian anomaly	0.152	1.000	0.263
Laplacian saliency	0.278	1.000	0.435
NG-BEVA	0.079	1.000	0.147
<i>Mines (168×168)</i>			
Nyström anomaly	0.151	0.846	0.256
Nyström saliency	0.144	1.000	0.252
Laplacian anomaly	0.088	0.692	0.157
Laplacian saliency	0.116	1.000	0.208
NG-BEVA	0.042	1.000	0.081

Statistike krivih detekcija

Algoritam	Sumnjive komponente	Krive detekcije	FA/Slika	FA/MPix
<i>Ships (200×200)</i>				
Nyström anomaly	12	8	2.67	66.7
Nyström saliency	34	31	10.33	258.3
Laplacian anomaly	56	53	17.67	441.7
Laplacian saliency	59	56	18.67	466.7
NG-BEVA	4	1	0.33	8.3
<i>Shipwrecks (200×200)</i>				
Nyström anomaly	42	11	2.20	55.0
Nyström saliency	47	11	2.20	55.0
Laplacian anomaly	68	28	5.60	140.0
Laplacian saliency	69	13	2.60	65.0
NG-BEVA	118	58	11.60	290.0
<i>Mines (168×168)</i>				
Nyström anomaly	74	62	5.17	183.1
Nyström saliency	92	77	6.42	227.3
Laplacian anomaly	108	93	7.75	274.6
Laplacian saliency	118	99	8.25	292.3
NG-BEVA	317	296	24.67	874.0

Detekcija anomalija s 50% pokrivenosti

Algoritam	Detektirano	Promašeno	P(D) (%)	Prosječna pokrivenost (%)
Nyström saliency	2	3	40.0	0.33
Nyström anomaly	0	5	0.0	0.20
Laplacian saliency	1	4	20.0	0.33
Laplacian anomaly	2	3	40.0	0.33
NG-BEVA	0	5	0.0	0.20

Table 1: Rastav brzina po podacima i algoritmu

Algoritam	n	Prosjek	Std. dev.	Medijan	Min	Max
<i>Ships</i> (200×200)						
Laplacian anomaly	3	65.40	1.33	64.97	64.34	66.90
Laplacian saliency	3	61.16	0.97	61.26	60.15	62.08
Nyström anomaly	3	20.83	0.49	21.06	20.27	21.15
Nyström saliency	3	16.12	0.94	16.21	15.13	17.00
NG-BEVA	3	2.87	0.57	2.69	2.42	3.52
<i>Shipwrecks</i> (200×200)						
Laplacian anomaly	5	65.37	0.70	65.75	64.45	66.10
Laplacian saliency	5	59.47	0.78	59.58	58.21	60.37
Nyström anomaly	5	20.59	0.54	20.30	20.16	21.45
Nyström saliency	5	15.04	0.51	15.07	14.34	15.67
NG-BEVA	5	3.79	1.12	3.26	2.76	5.60
<i>Mines</i> (168×168)						
Laplacian anomaly	12	34.78	0.70	34.86	32.74	35.38
Laplacian saliency	12	29.36	0.43	29.29	28.78	30.17
Nyström anomaly	12	10.60	0.24	10.56	10.29	11.20
Nyström saliency	12	7.89	0.29	7.94	7.33	8.19
NG-BEVA	12	2.48	0.22	2.42	2.29	2.84

Hvala na pozornosti!

-  G. Mishne and I. Cohen, “Multiscale Anomaly Detection Using Diffusion Maps,” *IEEE Journal of Selected Topics in Signal Processing*, vol. 7, no. 1, pp. 111–123, 2013.
-  G. Mishne and I. Cohen, “Multiscale Anomaly Detection Using Diffusion Maps and Saliency Score,” in *Proc. IEEE ICASSP*, pp. 2823–2827, 2014.
-  E. Madar, D. Malah, and M. Barzohar, “Non-Gaussian Background Modeling for Anomaly Detection in Hyperspectral Images,” in *Proc. 19th European Signal Processing Conference*, pp. 1125–1129, 2011.
-  C. Fowlkes, S. Belongie, F. Chung, and J. Malik, “Spectral Grouping Using the Nyström Method,” *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 26, no. 2, pp. 214–225, 2004.